

Mini-projet NLP : football ou basket-ball ?

Comparaison de trois approches de classification de textes

1 Cas d'usage et données

Besoin. À partir d'une courte description d'une action de jeu, retrouver automatiquement le sport concerné, par exemple pour ranger des commentaires ou des résumés de match. Deux classes : **football** (américain : *quarterback*, *touchdown*...) et **basket-ball**.

Données. Le jeu `its-zion-18/sports-text-dataset` (Hugging Face), en anglais. Il existe en deux versions : **original** (100 textes) et **augmented** (1 000 textes). On utilise la version augmentée, construite en déclinant chacun des 100 textes originaux en 10 variantes (reformulations, fautes de frappe ou simples copies) : la ligne i est une variante du texte $i \bmod 100$.

Exploration. 308 lignes sont des doublons (casse ignorée) et sont supprimées : il reste **692 textes uniques**, environ 7 par texte original. Les classes sont équilibrées (352 football, 340 basket-ball), les textes sont courts (une trentaine de mots) et de longueur comparable d'une classe à l'autre. Le vocabulaire est très marqué, mais certains mots sont communs aux deux sports (*defense*, *score*, *team*).

Protocole. Les variantes d'un même texte se ressemblant beaucoup, un découpage aléatoire des lignes mettrait des quasi-copies dans le train et le test. On découpe donc les **100 textes originaux** en 60/20/20 (stratifié par classe), et chaque variante suit son original :

	train	validation	test
Textes	421	139	132
Textes originaux	60	20	20

Le même découpage sert aux trois systèmes. Règles, vocabulaire et poids sont appris sur le train, les hyperparamètres sont fixés en regardant la validation, et le test n'est utilisé qu'une fois, à la fin. La seed est fixée (213). Un nettoyage commun produit une colonne **tokens** : minuscules, suites de lettres uniquement, suppression des mots outils anglais (liste de scikit-learn) et des mots d'une lettre.

2 Les trois systèmes

2.1 Règles à base de mots-clés (sans apprentissage)

Pour chaque classe, on garde les **15 mots les plus fréquents du train qui n'apparaissent jamais dans l'autre classe**. Ce filtre écarte les mots partagés (*team*, *game*, *ball*, *ability*...) qui dominent les fréquences brutes des deux classes.

- **Football** : *quarterback*, *running*, *touchdown*, *defense*, *deep*, *zone*, *field*, *lines*, *short*, *territory*, *receiver*, *yardage*, *tackle*, *wide*, *catching*.
- **Basket-ball** : *player*, *shot*, *hits*, *basket*, *pointer*, *clutch*, *shooting*, *free*, *court*, *rebound*, *fouled*, *lay*, *throw*, *jumper*, *fast*.

Un texte est attribué au sport dont il contient le plus de mots-clés. En cas d'égalité (y compris aucun mot trouvé), on choisit football, la classe majoritaire du train.

Limites attendues : fautes de frappe (*receiver* n'est pas reconnu), absence de contexte, mots génériques restés dans les lexiques (*player*, *fast*, *short*), vocabulaire limité à 15 mots par sport, et choix par défaut qui pénalise toujours le basket-ball.

2.2 MLP sur TF-IDF (PyTorch)

Les tokens sont transformés en vecteurs TF-IDF (vocabulaire de 982 mots appris sur le train), puis passés dans un réseau TF-IDF $\rightarrow$ Linear(32) $\rightarrow$ ReLU $\rightarrow$ Dropout(0,3) $\rightarrow$ Linear(2), soit environ 31 500 poids, entraîné avec l'entropie croisée.

Hyperparamètre	Valeur	Justification
Neurones cachés	32	environ 420 textes : un réseau plus gros apprendrait par cœur
Dropout	0,3	limite le sur-apprentissage
Optimiseur	Adam, lr = 0,01	converge vite sur un si petit réseau
Époques	30	la perte de validation est minimale vers 20 époques
Batch	tout le train	les données tiennent en mémoire

Les courbes de perte (dans le notebook) montrent une baisse commune au début, puis la perte de train tend vers 0 tandis que celle de validation atteint son minimum à l'époque 21 (0,18) et remonte légèrement (0,20 à l'époque 30) : début de sur-apprentissage, d'où l'arrêt à 30 époques.

2.3 Transformer pré-entraîné : DistilBERT

Modèle. `distilbert-base-uncased` : les textes sont en anglais, et cette version allégée de BERT (66 millions de paramètres) tourne sur CPU.

Tokenisation. Le tokeniseur WordPiece du modèle, appliqué au **texte brut** (le modèle a besoin de la phrase complète). Les mots inconnus sont découpés en sous-mots : *receiver* devient **rc ##ee ##iver** au lieu d'être perdu. Longueur maximale : 64 tokens (le texte le plus long en fait 58, rien n'est tronqué).

Entraînement. On fait le minimum demandé : l'encodeur est **gelé**. Chaque texte passe une fois dans DistilBERT pour en extraire le vecteur du token [CLS] (768 valeurs), puis une tête linéaire $768 \rightarrow 2$ (1 538 poids) est entraînée avec Adam (lr = 0,01) pendant 100 époques, sur tout le train à la fois. La perte de validation baisse jusqu'à la fin sans remonter. Affiner tout le modèle aurait été bien plus coûteux sur CPU, pour un gain probablement faible ici.

3 Résultats

Validation. Les trois systèmes obtiennent une accuracy de 0,935 et un F1 macro de 0,934, avec 9 erreurs chacun sur 139 textes.

Test (utilisé une seule fois).

Système	Accuracy	Précision	Rappel	F1 macro	Erreurs	Entraînement	Inférence (test)
Règles	0,848	0,875	0,861	0,848	20	–	1,7 ms
MLP	1,000	1,000	1,000	1,000	0	0,08 s	3,7 ms
DistilBERT	1,000	1,000	1,000	1,000	0	4,9 s	1,6 s

Précision, rappel et F1 sont en moyenne macro. Les matrices de confusion sont dans le notebook : les 20 erreurs des règles sont toutes des textes de basket-ball classés football. Pour DistilBERT, les temps incluent le passage dans l'encodeur, obligatoire pour tout nouveau texte.

Ces 100 % sont à relativiser : les 132 textes du test ne proviennent que de **20 textes originaux**. Les deux modèles ont surtout reconnu 20 situations de jeu, et une erreur sur un texte original se répète sur toutes ses variantes.

4 Analyse des erreurs

Règles (test). Les 20 erreurs viennent de 5 textes originaux seulement, et sont toutes des égalités tranchées en faveur du football :

1. *The agile guard [...] two-handed dunk* : aucun mot-clé. *Dunk*, pourtant très typique, est trop rare dans le train pour entrer dans le lexique (7 variantes en erreur).
2. *power forward [...] deep in the post [...] hook shot* : *shot* compte pour le basket, mais *deep* compte pour le football, où il n'apparaît que dans le train. Même mot, deux sens (9 variantes en erreur).
3. *a wide-open three-pointer* : la tokenisation coupe *wide-open* et *wide* (de *wide receiver*) passe côté football. Égalité 1–1.
4. *perfect fast break [...] alley-oop, catching the ball* : 2 mots-clés de chaque côté, les fautes cassent les autres indices (*break, alley-oop*).
5. *gets a key steal [...] easy score* : vocabulaire du basket (*steal, break*) mais absent du lexique.

MLP et DistilBERT (validation, faute d'erreurs sur le test).

6. *The coach [...] calls a timeout [...] final seconds of the fourth quarter* : les trois systèmes se trompent sur les 7 variantes. Le texte est réellement ambigu (temps mort et 4^e quart-temps existent dans les deux sports) : c'est une limite des données.
7. *The player hits a half-court shot* : les règles ont raison (*hits, shot*), le MLP se trompe sur les deux variantes ; les fautes font disparaître *player* et *court*. DistilBERT a raison grâce aux sous-mots.
8. *The quarterback throws a screen pass to the wide receiver* : DistilBERT prédit basket-ball. Les mots du football sont tous mal écrits et il reste *screen*, action typique du basket. Les règles ont raison, mais par chance (aucun mot-clé, football par défaut).

5 Conclusion

	Règles	MLP	DistilBERT
F1 macro (test)	0,85	1,00	1,00
Coût d'entraînement	aucun	< 0,1 s	≈ 5 s
Taille	30 mots	≈ 31 500 poids	66 M paramètres (≈ 250 Mo)
Explicabilité	totale	partielle	faible

Nous retiendrions le MLP. Il fait jeu égal avec DistilBERT sur la validation comme sur le test, pour un coût bien plus faible : entraînement en moins d'une seconde, prédiction en quelques millisecondes, pas de modèle lourd à télécharger. Sur un problème au vocabulaire aussi marqué, la compréhension du contexte de DistilBERT n'apporte pas de gain visible.

Les **règles** sont transparentes et immédiates, mais trop fragiles : un mot absent du lexique suffit à faire basculer la décision, et la règle d'égalité crée un biais systématique vers le football. **DistilBERT** deviendrait pertinent avec des textes plus variés ou plus bruités, car c'est le seul système qui résiste en partie aux fautes de frappe.

Limites de l'étude. Les données sont très petites (100 textes originaux) et les variantes se ressemblent beaucoup : les scores donnent un ordre de grandeur, pas une mesure précise, et quelques textes originaux suffisent à faire varier fortement les résultats. Certains textes, comme celui du coach, sont ambigus quelle que soit la méthode.